


以带 1 层隐藏层的前馈型神经网络为例解释反向传播法（Back Propagation,BP）



其中， i_1, i_2 是输入层神经元， h_1, h_2 是隐藏层神经元， O 是输出层神经元， b_1, b_2 分别是输入层和隐藏层的偏置。除了输入层外，其他两层的神经元接受上层输入的数据，经激活函数变换后输出至下一层（输出层神经元的输出是模型最终输出）。假设隐藏层和输出层的激活函数均为 Sigmoid，即

$$f(x) = \frac{1}{1 + e^{-x}}$$

Sigmoid 函数的导函数：

$$f'(x) = f(x)(1 - f(x))$$

h_1, h_2 的输入是 i_1, i_2 的加权再加上偏置 b_1 ，即：

$$net_{h_1} = i_1 w_1 + i_2 w_2 + b_1$$

$$net_{h_2} = i_1 w_3 + i_2 w_4 + b_1$$

h_1, h_2 的输出是激活函数作用在输入上：

$$out_{h_1} = f(net_{h_1})$$

$$out_{h_2} = f(net_{h_2})$$

同样的， O 的输入来自 h_1, h_2 的输出的加权再加上偏置 b_2 ，即

$$net_O = out_{h_1} w_5 + out_{h_2} w_6 + b_2$$

O 的输出是激活函数作用在输入上：

$$out_O = f(net_O)$$

再假设损失函数是均方误差：

$$E = \frac{1}{2}(target - output)^2 = \frac{1}{2}(target - out_O)^2$$

则根据链式法则可求出 E 对 w_5 的梯度：

$$\frac{\partial E}{\partial w_5} = \frac{\partial E}{\partial out_O} \frac{\partial out_O}{\partial net_O} \frac{\partial net_O}{\partial w_5}$$

由于

$$\frac{\partial E}{\partial out_O} = -(target - out_O)$$

$$\frac{\partial out_O}{\partial net_O} = f'(net_O) = f(net_O)(1 - f(net_O)) = out_O(1 - out_O)$$

$$\frac{\partial net_O}{\partial w_5} = \frac{\partial(out_{h_1}w_5 + out_{h_2}w_6 + b_2)}{\partial w_5} = out_{h_1}$$

故

$$\frac{\partial E}{\partial w_5} = -(target - out_O)out_O(1 - out_O)out_{h_1}$$

类似可求出 $\frac{\partial E}{\partial w_6}$ 和 $\frac{\partial E}{\partial b_2}$

E 对 w_1 的梯度是：

$$\frac{\partial E}{\partial w_1} = \frac{\partial E}{\partial out_O} \frac{\partial out_O}{\partial net_O} \frac{\partial net_O}{\partial out_{h_1}} \frac{\partial out_{h_1}}{\partial net_{h_1}} \frac{\partial net_{h_1}}{\partial w_1}$$

其中 $\frac{\partial E}{\partial out_O}$ 、 $\frac{\partial out_O}{\partial net_O}$ 已经求出，而

$$\frac{\partial net_O}{\partial out_{h_1}} = \frac{\partial(out_{h_1}w_5 + out_{h_2}w_6 + b_2)}{\partial out_{h_1}} = w_5$$

$$\frac{\partial out_{h_1}}{\partial net_{h_1}} = f'(net_{h_1}) = f(net_{h_1})(1 - f(net_{h_1})) = out_{h_1}(1 - out_{h_1})$$

$$\frac{\partial net_{h_1}}{\partial w_1} = \frac{\partial(i_1w_1 + i_2w_2 + b_1)}{\partial w_1} = i_1$$

故

$$\frac{\partial E}{\partial w_1} = -(target - out_O)out_O(1 - out_O)w_5out_{h_1}(1 - out_{h_1})i_1$$

结合梯度下降法， w_1 和 w_5 的更新公式为：

$$w_1^+ = w_1 - \eta \frac{\partial E}{\partial w_1}$$

$$w_5^+ = w_5 - \eta \frac{\partial E}{\partial w_5}$$

同理可求出其他参数的更新公式。